

MBA
USP
ESALQ

SÉRIES TEMPORAIS

Prof. Fabiano Guasti Lima

***A responsabilidade pela idoneidade, originalidade e licitude dos conteúdos didáticos apresentados é do professor.**




Proibida a reprodução, total ou parcial, sem autorização. Lei nº 9610/98

SÉRIES TEMPORAIS

Tópicos

Leitura de dados em série temporal; Plotagem e decomposição de séries temporais; Método de Holt-Winters; Decomposição de séries não sazonais; Alisamento exponencial (exponential smoothing); Decomposição de séries sazonais e ajustamento sazonal; Forecast; Modelos ARIMA; Diferenciação de séries temporais; Seleção de modelos ARIMA; Forecast para modelos ARIMA; Exemplos e exercícios adicionais dos modelos estudados.


Referências



<https://www.msperlin.com/adfeR/>

<https://otexts.com/fpp3/>

Referências



SÉRIES TEMPORAIS

Conjunto de observações ordenadas no tempo.


$$\{X_t\}_{t=1}^n = \{X_1, X_2, \dots, X_n\}$$

Se $n \geq 50$, chama-se sucessão cronológica.

- Ordem: dependência de ordem!

- Índice IBOVESPA diário;
- Retorno das ações da Petrobrás mensal;
- Índices Mensais da Inflação no Brasil;
- Taxas de Câmbio Real/US\$ diário

ELEMENTOS DE UMA SÉRIE TEMPORAL




Fonte: B3, abril, 2023 – Acesso em 05/04/2023

*A responsabilidade pela idoneidade, originalidade e licitude dos conteúdos didáticos apresentados é do professor.
Proibida a reprodução, total ou parcial, sem autorização. Lei nº 9610/98

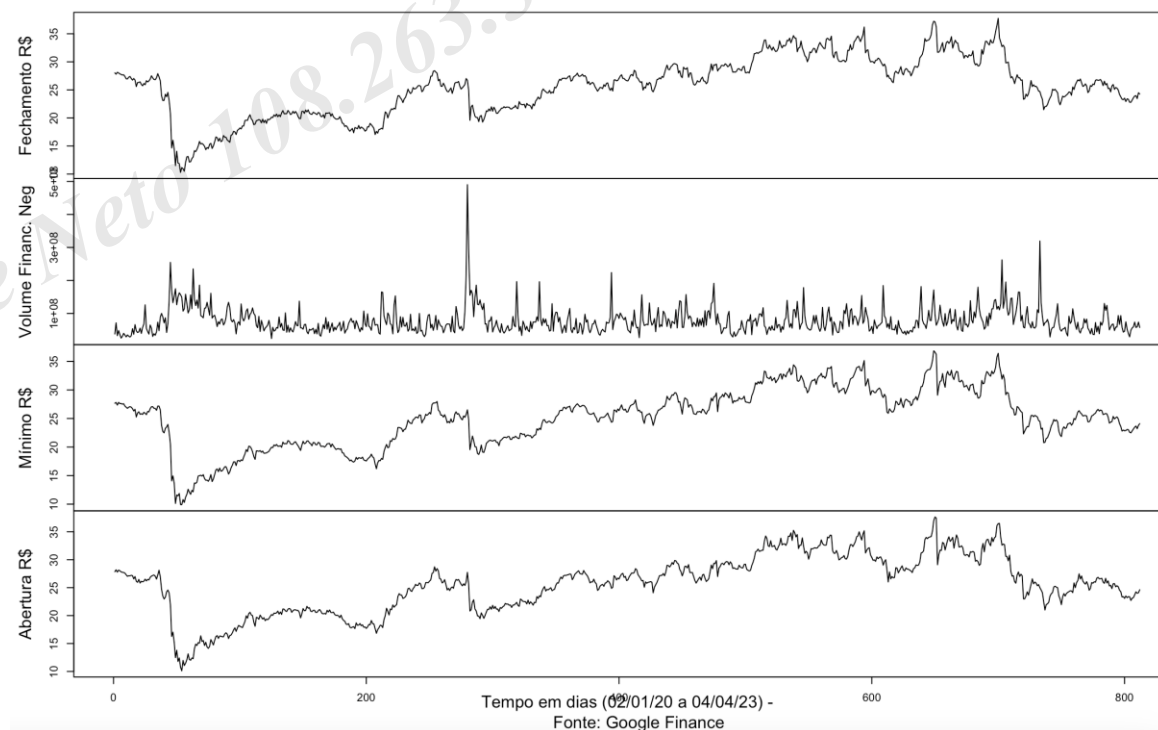
Univariadas e Multivariadas

- **Univariadas:** apenas uma variável conectada ao tempo
- **Multivariadas:** duas ou mais variáveis conectadas ao tempo

Cotações da PETR4 - jan/2020 a abr/2023




Informações da ação PETR4



Fonte: [googlefinance](https://www.google.com/finance), abril/2023


Exemplos Séries Temporais



Fonte: <https://www.gov.br/anac/pt-br/assuntos/dados-e-estatisticas/dados-estatisticos/dados-estatisticos>


Exemplos Séries Temporais

Faturamento Trimestral - Acumulado da AMBEV SA - 1T/2000 ao 4T/2022




Fonte: CVM, dez/2022

Exemplos Séries Temporais



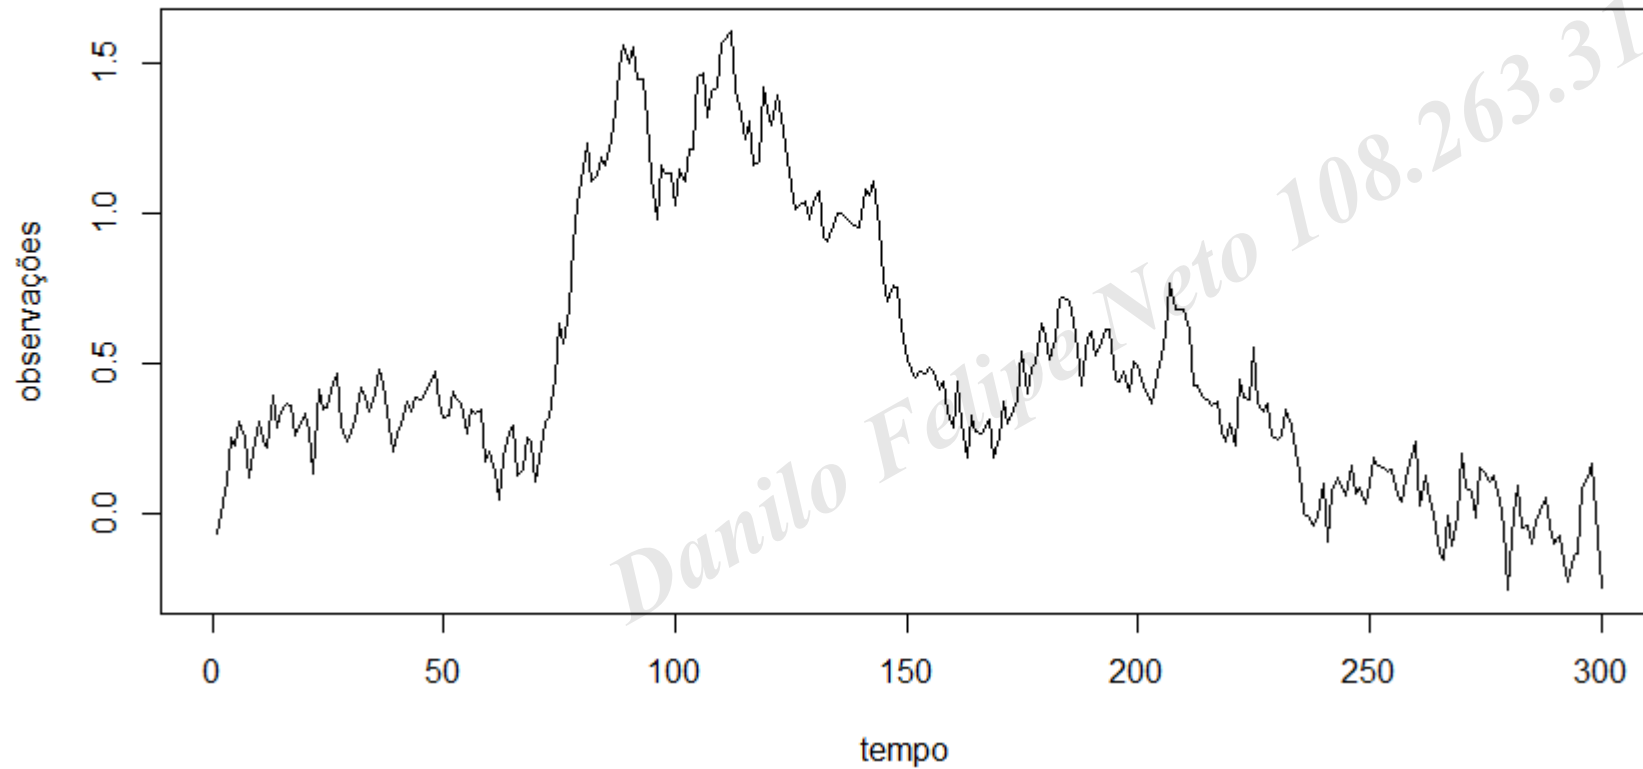
Fonte: <http://sidc.be/silso/infosnmtot>

Exemplo Séries Temporais



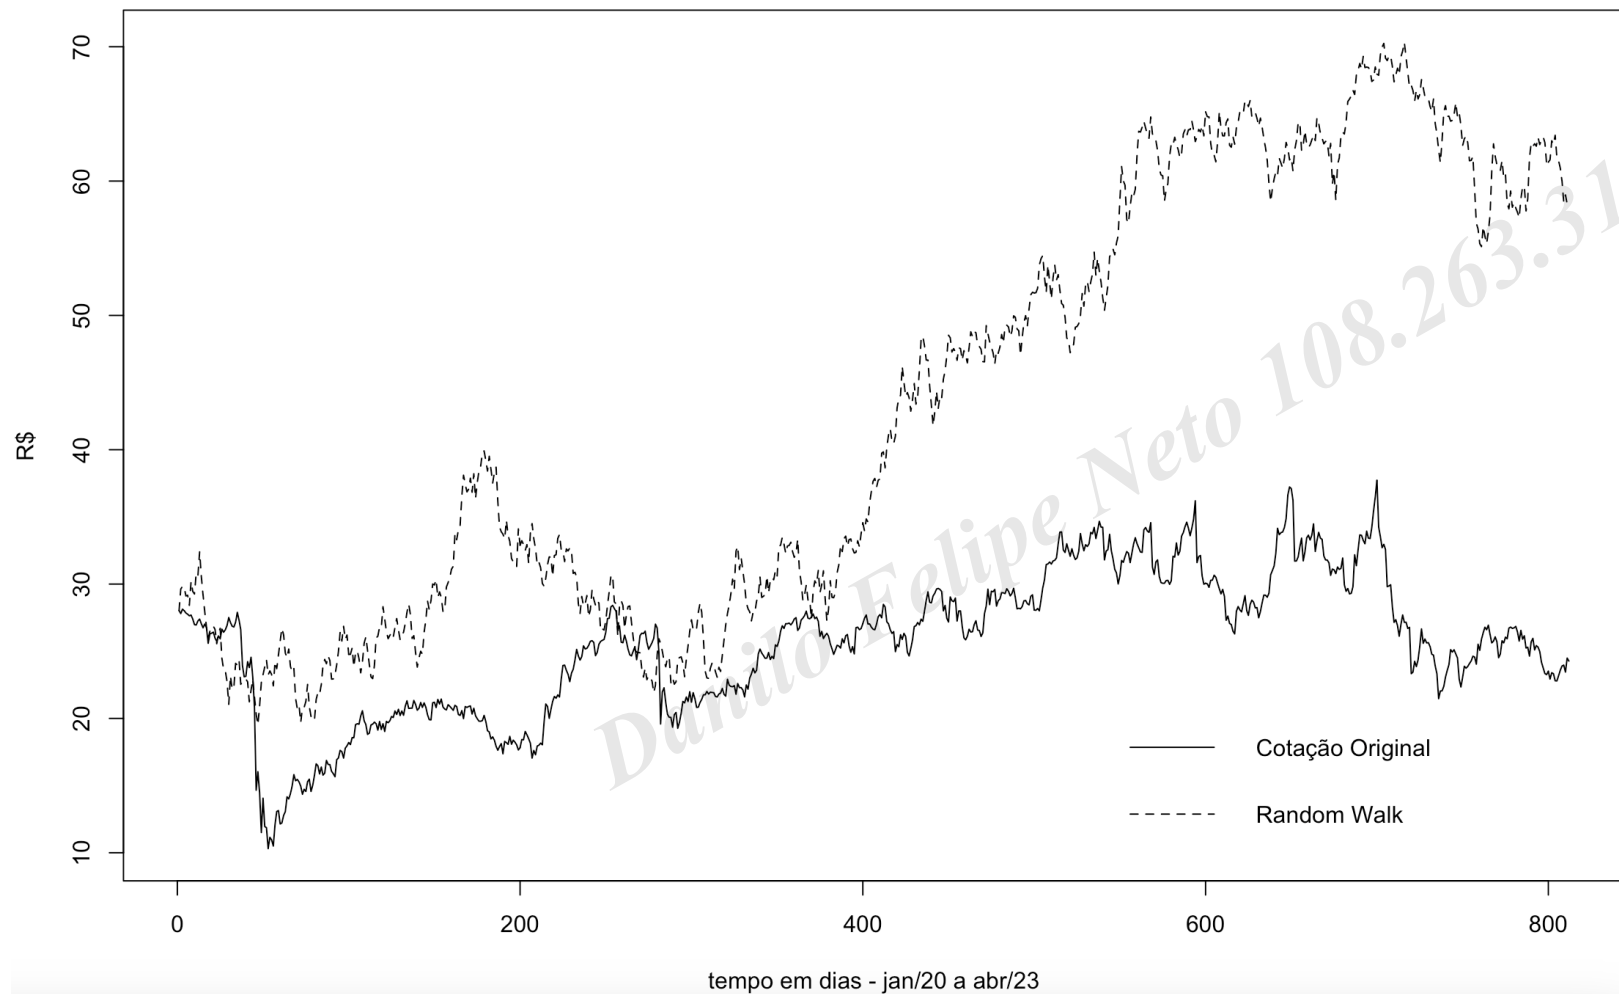
Exemplos Séries Temporais

Passeio Aleatório

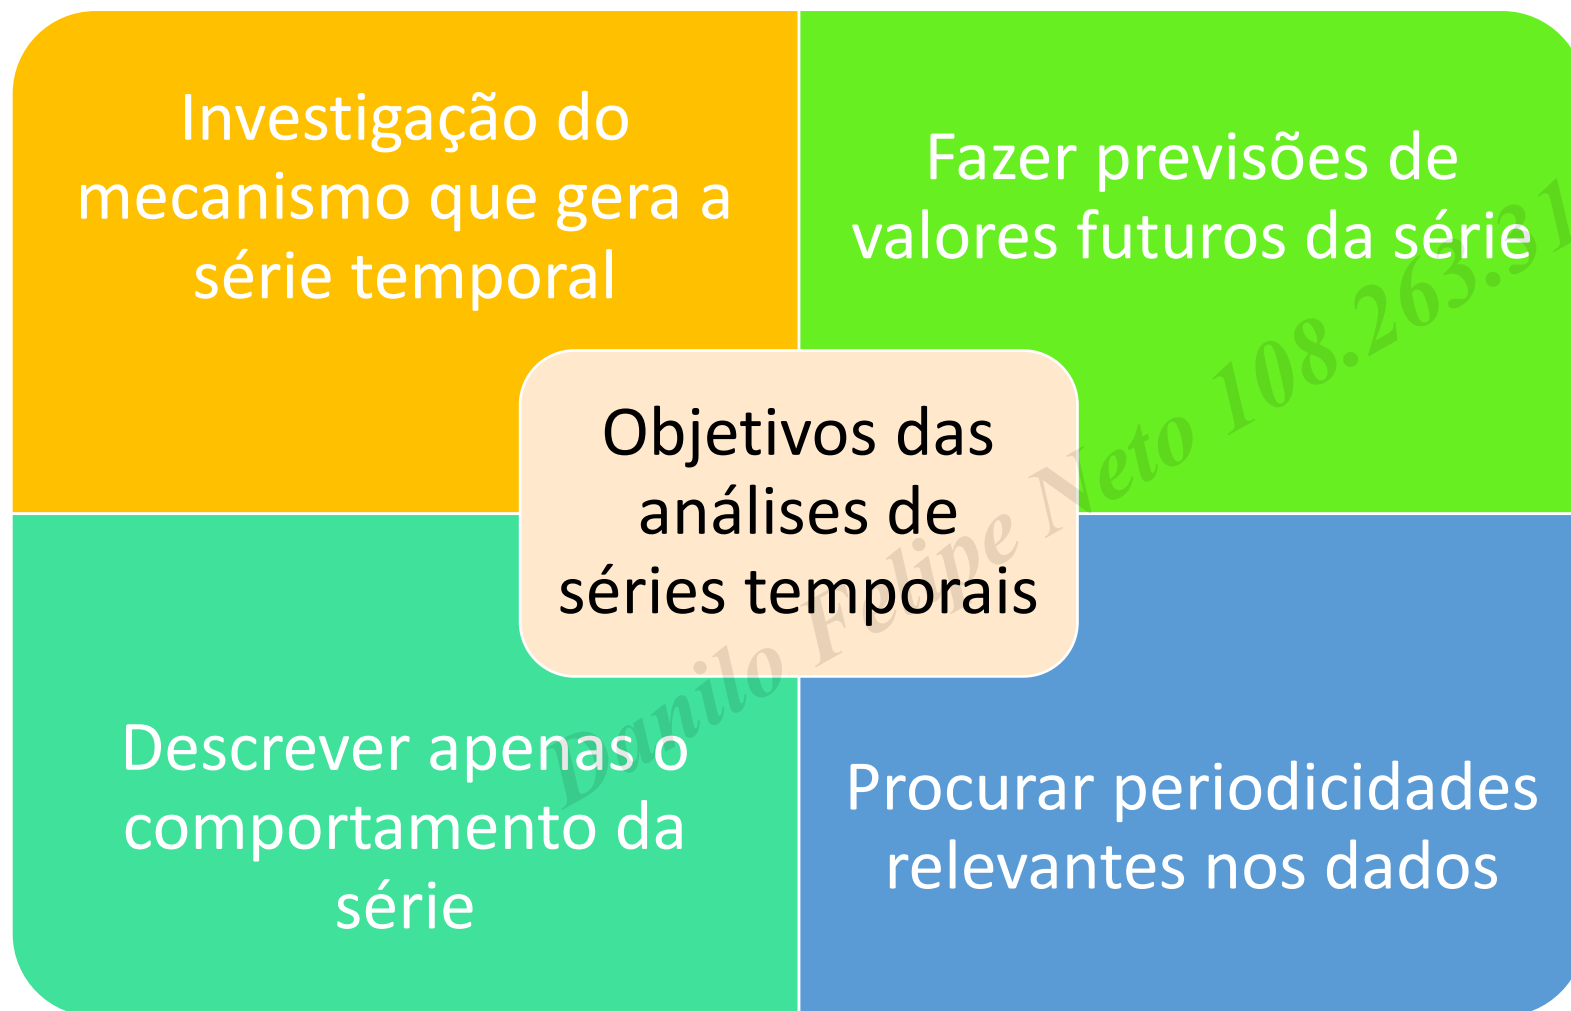


Exemplos Séries Temporais

Cotação Original de Fechamento e Random Walk



Objetivos do Estudo de Séries de Tempo



Histórico...


- **Stigler (1699)** – primeiro esquema “empírico” da demanda publicado por Charles Davenant;
- **Rodolfo Enini (1907)** – primeiros estudos;
- **1930** – Econometric Society;
- **Antes de 1955** – Modelos Clássicos de Decomposição;
- **1957 – 1962** – Modelos de Alisamento Exponencial (Holt-Winters e Brown);
- **Décadas de 60/70** – Modelos de Box-Jenskins (ARIMA);
- **Década de 80** – Modelos estruturais clássicos e bayesianos (Filtro de Kalman);
- **Década de 80/90** – Cointegração e econometria de Séries Temporais.

Séries Temporais



George Box (1919-2013)

Fonte: Google Imagens



Gwilym Jenkins (1932-1982)

Todos os modelos
estão errados, mas
alguns são úteis.

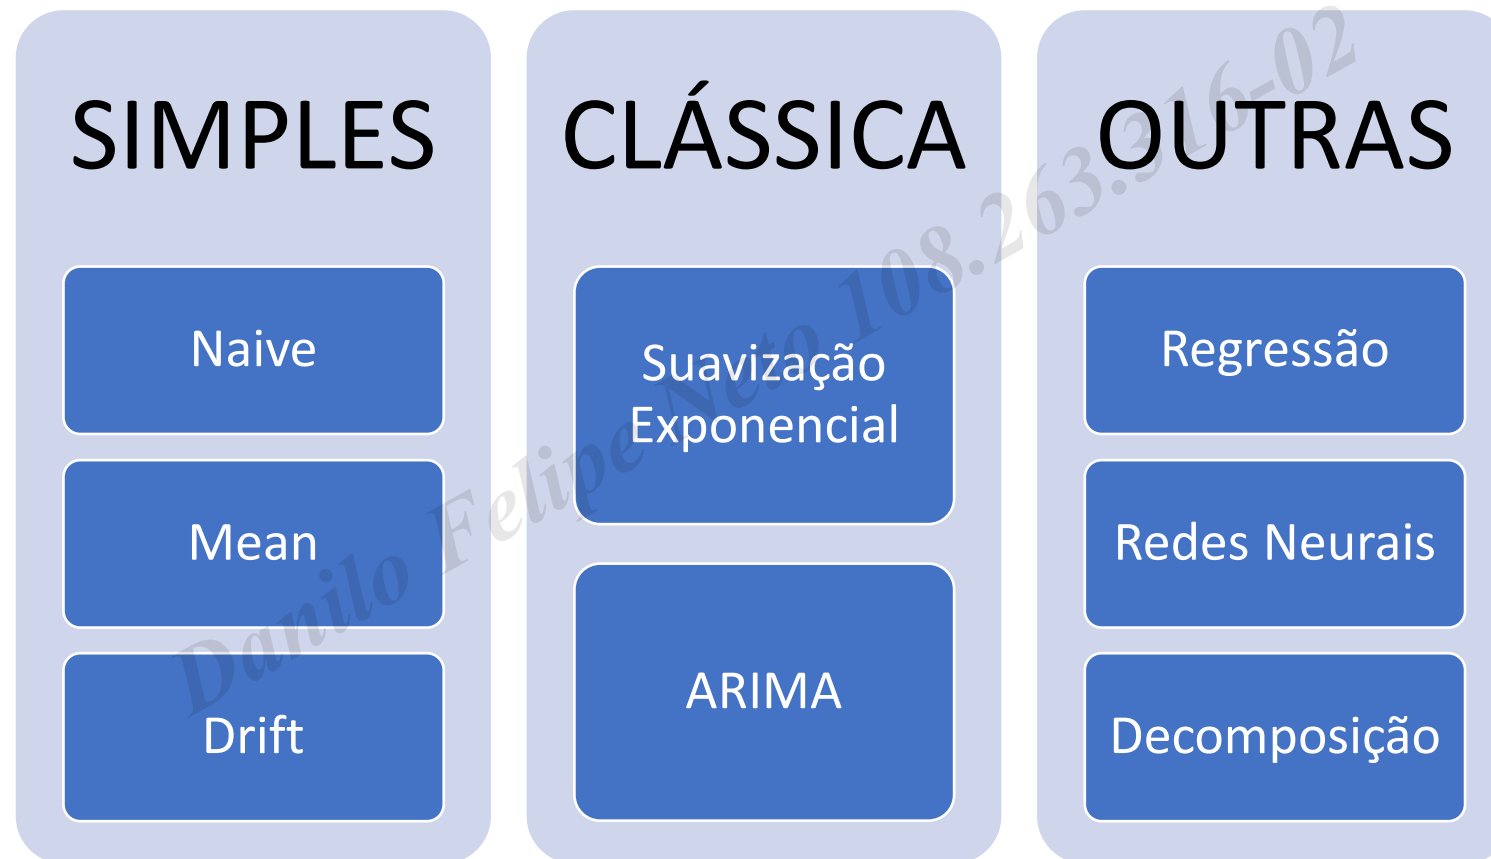
Classificação das Séries Temporais

- **Discretas:** são séries em que o intervalo de observações (t) pertence a um conjunto discreto. Ou seja, as observações são feitas em intervalos de tempo fixos.
- **Contínuas:** são séries em que as observações são obtidas continuamente através de algum intervalo no tempo.

Classificação das Séries Temporais

- **Determinística:** quando pode ser descrita por uma função matemática para estabelecer exatamente os valores futuros da série.
- **Estocástica:** quando os valores futuros da série somente podem ser estabelecidos em termos probabilísticos, pois o modelo compõe-se também de um termo aleatório.

Métodos Estudados



Métodos SIMPLES

- **NAIVE:** Projeta o último valor para o futuro
- **NAIVE SAZONAL:** Considera o último valor no mesmo período de tempo (para séries com sazonalidade)
- **Média:** usa a média histórica como previsão para o futuro
- **Drift:** faz uma previsão que acompanha a tendência da série (equivale a traçar uma reta entre o primeiro e o último ponto)

Métodos SIMPLES

- **NAIVE:** Projeta o último valor para o futuro

$$\{X_t\}_{t=1}^n = \{X_1, X_2, \dots, X_n\}$$

$$X_{t+1} = X_t$$

$$X_{t+h} = X_t \pm Z_{\alpha/2\%} \cdot \sigma_{\text{resíduos}} \cdot \sqrt{h}$$

Métodos SIMPLES

- **NAIVE SAZONAL:** Projeta o último período sazonal

$$\{X_t\}_{t=1}^n = \{X_1, X_2, \dots, X_n\}$$

$$X_{t+1} = X_{t+m}$$

$$X_{t+h} = X_{t+m} \pm Z_{\alpha/2\%} \cdot \sigma_{resíduos} \cdot \sqrt{k+1}$$

$$k = (\text{parte inteira}) \left(\frac{h-1}{m} \right)$$

Métodos SIMPLES

- **MÉDIA:** média de toda a série

$$\{X_t\}_{t=1}^n = \{X_1, X_2, \dots, X_n\}$$

$$X_{t+1} = Média = \frac{1}{n} \cdot \sum_{t=1}^n X_t$$

$$X_{t+h} = Média \pm t_{\alpha/2\%} \cdot \sigma_{resíduos} \cdot \sqrt{1 + \frac{1}{n}}$$

Métodos SIMPLES

- **DRIFT:** equivale a traçar uma reta entre o primeiro e o último ponto

$$\{X_t\}_{t=1}^n = \{X_1, X_2, \dots, X_n\}$$

$$X_{t+h} = X_t + h \cdot \frac{X_t - X_1}{t - t_0}$$

$$X_{t+h} = X_t \pm Z_{\alpha/2\%} \cdot \sigma_{resíduos} \cdot \sqrt{h \cdot \left(1 + \frac{h}{n_{resíduos} - 1}\right)}$$

Estatísticas de Erro das Previsões

- **ME:** Mean Error – É a média da diferença entre realizado e o previsto.

$$erro_t = X_t - \hat{X}_t$$

$$ME = \frac{\sum_{t=1}^h erro_t}{h}$$

- **MAE:** Mean Absolute Error – É a média da diferença absoluta entre realizado e previsto

$$MAE = \frac{\sum_{t=1}^h |erro_t|}{h}$$

Estatísticas de Erro das Previsões

- **RMSE:** Root Mean Square Error – É o desvio padrão total da amostra da diferença entre o previsto e o realizado.

$$RMSE = \sqrt{\frac{\sum_{t=1}^h (erro_t)^2}{h}}$$

Estatísticas de Erro das Previsões

- **MPE:** Mean Percentage Error – É a diferença percentual do erro.

$$MPE = \frac{\sum_{t=1}^h \frac{erro_t}{X_t}}{h} \times 100\%$$

- **MAPE:** Mean Absolute Percentage Error – É a diferença absoluta percentual do erro.

$$MAPE = \frac{\sum_{t=1}^h \frac{|erro_t|}{X_t}}{h} \times 100\%$$

Estatísticas de Erro das Previsões

- **TIC:** Theil Inequality Coefficient – **Theil's U**

É o grau de ajuste da previsão. Quanto menor, melhor. Zero ideal.

$$\text{Theil's } U = \sqrt{\frac{\sum_{t=1}^h \left(\frac{\hat{X}_{t+1} - X_{t+1}}{X_t} \right)^2}{\sum_{t=1}^h \left(\frac{X_{t+1} - X_t}{X_t} \right)^2}}$$

Estatísticas de Erro das Previsões


- **ACF1:** First-Order Autocorrelation Function –
Aucorrelação dos resíduos.

$$ACF_k = \frac{cov(R_{it}, R_{i,t-k})}{variância(R_{it})}$$

Métodos CLÁSSICOS

- **DECOMPOSIÇÃO:** projeções por decomposição da série
- **SUAVIZAÇÃO EXPONENCIAL:** método de amortecimento (suavização), ideal para tendências e inclui variação sazonal
 - **Aditivo:** para variação sazonal constante
 - **Multiplicativo:** variação sazonal varia na série

Médias Móveis



Fonte: <https://covid.saude.gov.br/>

Componentes de uma série temporal

TENDÊNCIA

Movimento oculto no dados, seguindo uma direção - crescente, decrescente ou estacionária

Sazonal

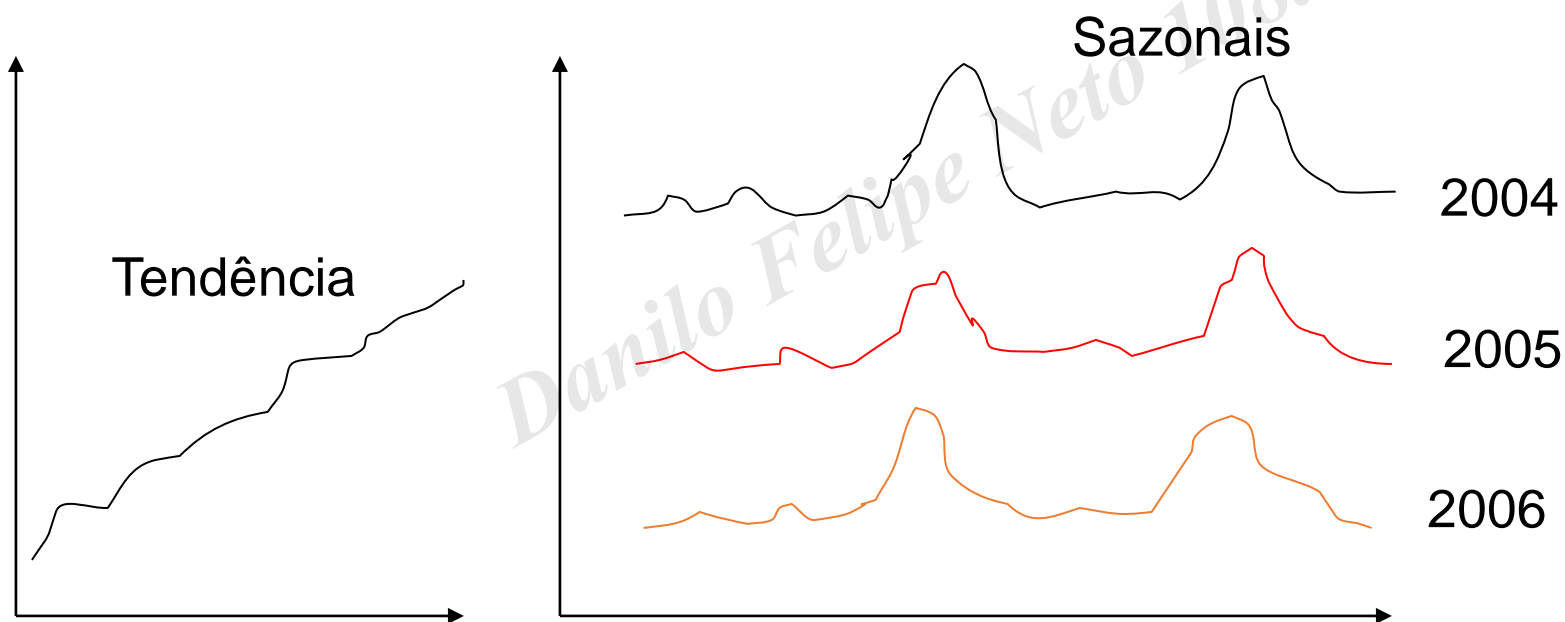
Flutuações regulares dentro de um período completo de tempo(dia, semana, mês, etc.)
- Representam um tipo de padrão que se repete. (picos, depressões) normalmente dentro de um ano

CÍCLICA

Flutuações de **longo** prazo nos dados e são similares aos fatores sazonais. Padrão que se repete com regularidade mas sem período fixo


Série com tendência e sazonalidade

Sazonalidade são as flutuações regulares dentro de um período completo de tempo (um dia, uma semana, um mês, etc). O importante sobre fatores sazonais é que eles representam um tipo de padrão que se repete.



Série com ciclo

Ciclos São flutuações a longo prazo nos dados e são similares aos fatores sazonais. Eles podem ser difíceis de serem identificados a menos que uma série de dados longa esteja disponível.



Série com tendência, sazonalidade e variações cíclicas

- Muitas séries apresentam junto a uma tendência variações cíclicas e sazonais;
- Estas variações aparecem devido a clima, fatores econômicos, hora, etc;
- Se estas variações podem ser observadas, a sua consideração pode ajudar a melhorar as previsões.
- São usados o método da decomposição:
- MULTIPLICATIVO
- ADITIVO

Aditivo

$$Y = T + C + S + E$$


- Y - valor da série no instante t
- T - componente de tendência para o instante t
- C - componente cíclica para o instante t
- S - componente sazonal para o instante t
- E - componente aleatória para o instante t

Multiplicativo

$$Y = T * C * S * E$$

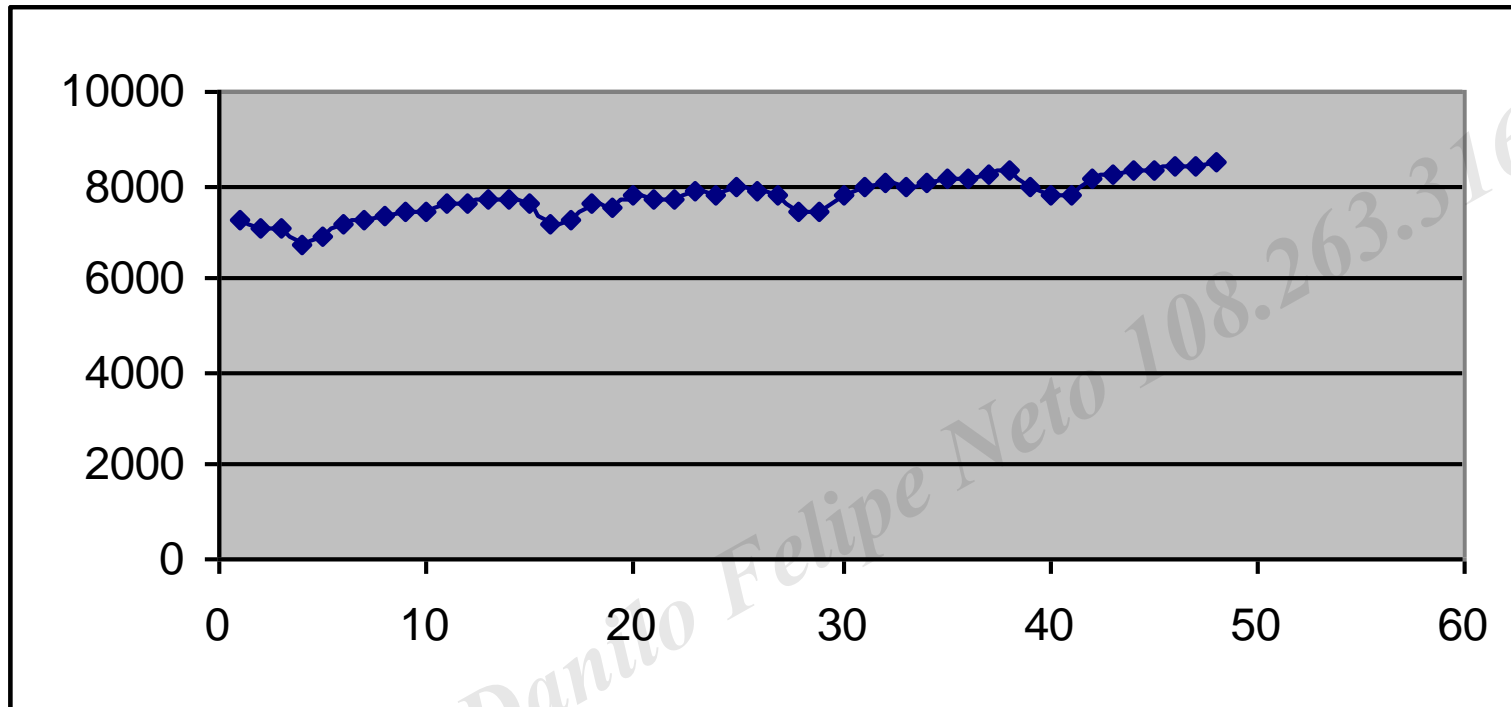
- Y - valor da série no instante t
- T - componente de tendência para o instante t
- C - componente cíclica para o instante t
- S - componente sazonal para o instante t
- E - componente aleatória para o instante t

Modelo Multiplicativo



O modelo multiplicativo é normalmente aplicado a dados em que o tamanho dos efeitos sazonais aumentam.

Modelo Aditivo



O modelo aditivo geralmente é considerado mais adequado para dados em que as flutuações sazonais permanecem aproximadamente do mesmo tamanho com o tempo.

Modelos de Suavização Exponencial (SES)

- Série temporal que não apresenta tendência e nem sazonalidade;
- Série temporal com Tendência mas sem sazonalidade – Suavização Exponencial de Holt (SEH)
- Série temporal com Tendência e Sazonalidade – Suavização Exponencial de Holt-Winters

Suavização Exponencial Simples (SES)

- Dá pesos maiores às observações mais recentes captando melhor as mudanças de comportamento.
- Previsão é igual ao último valor exponencial suavizado.

$$\{X_t\}_{t=1}^n = \{X_1, X_2, \dots, X_n\}$$

$$\hat{X}_{t+1} = \alpha X_t + (1 - \alpha)\hat{X}_t$$

$$\hat{X}_1 = X_1, \quad 0 \leq \alpha \leq 1, \quad t = 1, \dots, n$$

Suavização Exponencial Simples (SES) – Previsão

$$\hat{X}_t(h) = \hat{X}_t \pm Z_{\alpha/2\%} \cdot SE$$

$$SE = \sqrt{\frac{1}{n-1} \sum_{t=1}^{n-1} (\hat{X}_t - X_t)^2} \quad \text{Erro para } h = 1$$

$$SE_h = SE \times \sqrt{1 + (h-1) \cdot \alpha^2}$$

Suavização Exponencial de Holt (SEH)

- Para Séries temporais com tendência linear

$$\{X_t\}_{t=1}^n = \{X_1, X_2, \dots, X_n\}$$

$$\hat{u}_t = \alpha X_t + (1 - \alpha)(\hat{u}_{t-1} + \hat{T}_{t-1})$$

$$\hat{T}_t = \beta(\hat{u}_t - \hat{u}_{t-1}) + (1 - \beta)(\hat{T}_{t-1})$$

$$\hat{X}_{t+1} = \hat{u}_t + \hat{T}_t$$

$$\hat{u}_1 = X_1, \quad \hat{T}_1 = 0, \quad 0 \leq \alpha \leq 1, \quad t = 1, \dots, n$$
$$0 \leq \beta \leq 1$$

Suavização Exponencial de Holt (SEH) – Previsão

$$\hat{X}_t(h) = \hat{X}_t \pm Z_{\alpha/2\%} \cdot SE$$

$$\underline{SE} = \sqrt{\frac{1}{n-1} \sum_{t=1}^{n-1} (\hat{X}_t - X_t)^2}$$

Suavização Exponencial de Holt (SEH) – Previsão

$$\hat{X}_t(h) = \hat{X}_t \pm Z_{\alpha/2} \cdot SE(h)$$

$$SE(h) = SE \cdot \sqrt{1 + k \cdot \alpha^2}$$

$$k = \sum_{i=2}^h (1 + \beta \cdot (i - 1))^2$$

Suavização Exponencial de Holt-Winters (HW - Aditivo)

- Para Séries temporais com comportamento sazonal (c=período sazonal).
 - **Modelo Aditivo**

$$\hat{X}_t = \hat{L}_{t-1} + \hat{T}_{t-1} + \hat{S}_{t-c} \quad \{X_t\}_{t=1}^n = \{X_1, X_2, \dots, X_n\}$$

$$\hat{L}_t = \alpha(\hat{X}_t - \hat{S}_{t-c}) + (1 - \alpha) \cdot (L_{t-1} + T_{t-1})$$

$$\hat{T}_t = \beta(\hat{L}_t - \hat{L}_{t-1}) + (1 - \beta) \cdot T_{t-1}$$

$$\hat{S}_t = \gamma(\hat{X}_t - \hat{L}_{t-1}) + (1 - \gamma) \cdot S_{t-c}$$

$$0 \leq \alpha \leq 1$$

$$0 \leq \beta \leq 1$$

$$0 \leq \gamma \leq 1 - \alpha$$

$$\hat{X}_{t+h} = \hat{L}_t + h\hat{T}_t + \hat{S}_{t+h-ch'}$$

$$h' = INT\left(\frac{(h-1)}{c}\right) + 1$$

Suavização Exponencial de Holt-Winters (HW - Aditivo) – Previsão

$$\hat{X}_t(h) = \hat{X}_t \pm Z_{\alpha/2} \cdot SE(h)$$

$$SE(h) = SE \cdot \sqrt{1 + \sum_{i=1}^{h-1} \varphi_i^2}$$

$$\varphi_i = \begin{cases} \alpha(1 + \beta i), & c \neq i - 1 \\ \alpha(1 + \beta i) + \gamma(1 - \alpha), & c = i - 1 \end{cases}$$

Suavização Exponencial de Holt-Winters (HW - Multiplicativo)

- Para Séries temporais com comportamento sazonal (c=período sazonal).
 - **Modelo Multiplicativo**

$$\hat{X}_t = (\hat{L}_{t-1} + \hat{T}_{t-1}) \cdot \hat{S}_{t-c} \quad \{X_t\}_{t=1}^n = \{X_1, X_2, \dots, X_n\}$$

$$\hat{L}_t = \alpha(\hat{X}_t / \hat{S}_{t-c}) + (1 - \alpha) \cdot (L_{t-1} + T_{t-1})$$

$$\hat{T}_t = \beta(\hat{L}_t - \hat{L}_{t-1}) + (1 - \beta) \cdot T_{t-1}$$

$$\hat{S}_t = \gamma(\hat{X}_t / \hat{L}_{t-1}) + (1 - \gamma) \cdot S_{t-c}$$

$$0 \leq \alpha \leq 1$$

$$0 \leq \beta \leq 1$$

$$0 \leq \gamma \leq 1 - \alpha$$

$$\hat{X}_{t+h} = (\hat{L}_t + \hat{T}_t) \cdot \hat{S}_{t+h-ch'}$$

$$h' = INT \left((h - 1) / c \right) + 1$$

Previsão

Modelo ETS (Error, Trend, Seasonal)

- Definirá o melhor modelo

| Erro | Tendência | Sazonalidade |
|------|-----------|--------------|
| A | N | N |
| M | A | A |
| Z | M | M |
| | Z | Z |

model = “AAA”

| Legenda | |
|---------|----------------|
| A | Aditivo |
| M | Multiplicativo |
| N | Nenhum |
| Z | Automático |

| Tendência | |
|-----------|---------------------------|
| Ad | Aditivo Amortecido |
| Md | Multiplicativo Amortecido |

Modelos de Séries Temporais


- **Série Estacionária:** movimento de tendência não é significativo ao longo do tempo.

| Série Estacionária | Série Não-Estacionária |
|--|---|
| <ul style="list-style-type: none">○ Média móvel○ Média móvel ponderada○ Alisamento exponencial | <ul style="list-style-type: none">○ Tendência linear○ Método de Holt |

MODELOS ARIMA



George Box (1919-2013)



Gwilym Jenkins (1932-1982)

Fonte: Google Imagens

“Nos modelos ARIMA os dados falam por si mesmo”

Modelos ARIMA (Box-Jenkins)

- Robusto: pode ser aplicado em praticamente qualquer tipo de série temporal
- Funciona melhor com dados estáveis, com poucos *outliers* (embora podemos removê-los) - `tsclean`
- **Requer dados estacionários**
 - Pode ser transformada usando diferenciação: remove tendências
 - Diferenciação: subtrai a observação atual da anterior
 - Diferenciação pode ser feita 1x: diferenciação de primeira ordem
 - Diferenciação 2x: diferenciação de segunda ordem (mais raro)

Tipos de Modelos – ARIMA não Sazonal

- **Modelos auto-regressivos (AR):** avalia a relação entre os períodos (*lags*): autocorrelação – extrai a influência;
- **Integrado (I):** Aplicado à diferenciação, quando necessário
- **Modelos médias móveis (MA):** avalia erros entre períodos e extrai esses erros;
- **Modelos auto-regressivos e de médias móveis (ARMA)**
- **Modelos auto-regressivos integrados e de médias móveis (ARIMA)**

Modelos ARIMA

ARIMA

(p,d,q)

q: ordem da média móvel

d: grau de diferenciação

p: ordem da parte autorregressiva

Modelos ARIMA

- $p = 1$, significa que uma determinada observação pode ser explicada pela observação prévio + erro
- $p = 2$, significa que uma determinada observação pode ser explicada por duas observações prévias + erro
- $d = 0$, significa que não é aplicada diferenciação
- $d = 1$, significa que será aplicada diferenciação de primeira ordem
- $d = 2$, significa que será aplicada diferenciação de segunda ordem
- $q = 1$, significa que uma determinada observação pode ser explicada pelo erro da observação prévia
- $q = 2$, significa que uma determinada observação pode ser explicada pelo erro de duas observações prévias.

Modelos ARIMA

- AR(1) ou ARIMA(1,0,0) – Apenas elemento auto-regressivo de 1ª ordem
- AR(2) ou ARIMA(2,0,0) – Apenas elemento auto-regressivo de 2ª ordem
- MA(1) ou ARIMA(0,0,1) – Apenas média móvel
- ARMA(1,1) ou ARIMA(1,0,1) – Auto-regressão e média móvel de 1ª ordem

Modelos ARIMA – Como definir os valores de p , d , e q

- p : ordem da parte autorregressiva: PACF
- d : grau de diferenciação – Teste de Estacionariedade
- q : ordem da média móvel: ACF

Danilo Felipe Neto 108.263.316-02

Escolha dos Modelos

- Critério de **AIC** – Critério de Informação de Akaike
 - O AIC estima a quantidade relativa de informações perdidas por um determinado modelo: quanto menos informações um modelo perde, maior a qualidade desse modelo e menor a pontuação AIC.
- Critério de **BIC** – Critério de Informação Bayesiano
 - BIC mais baixo implica em melhor ajuste.


Modelos ARIMA

- Série Estacionária: média e a autocovariância são constantes no tempo.
- Formas detectar estacionariedade:
 - Gráfico ACF da série (processo não estacionário apresenta lento decaimento da sua função de autocorrelação.
 - Série com tendência é o motivo mais comum para não estacionariedade

Modelos Simulados


$AR(1)$

$$X_t = 0,8X_{t-1} + \varepsilon_t$$




$MA(1)$

$$X_t = -0,3\varepsilon_{t-1} + \varepsilon_t$$



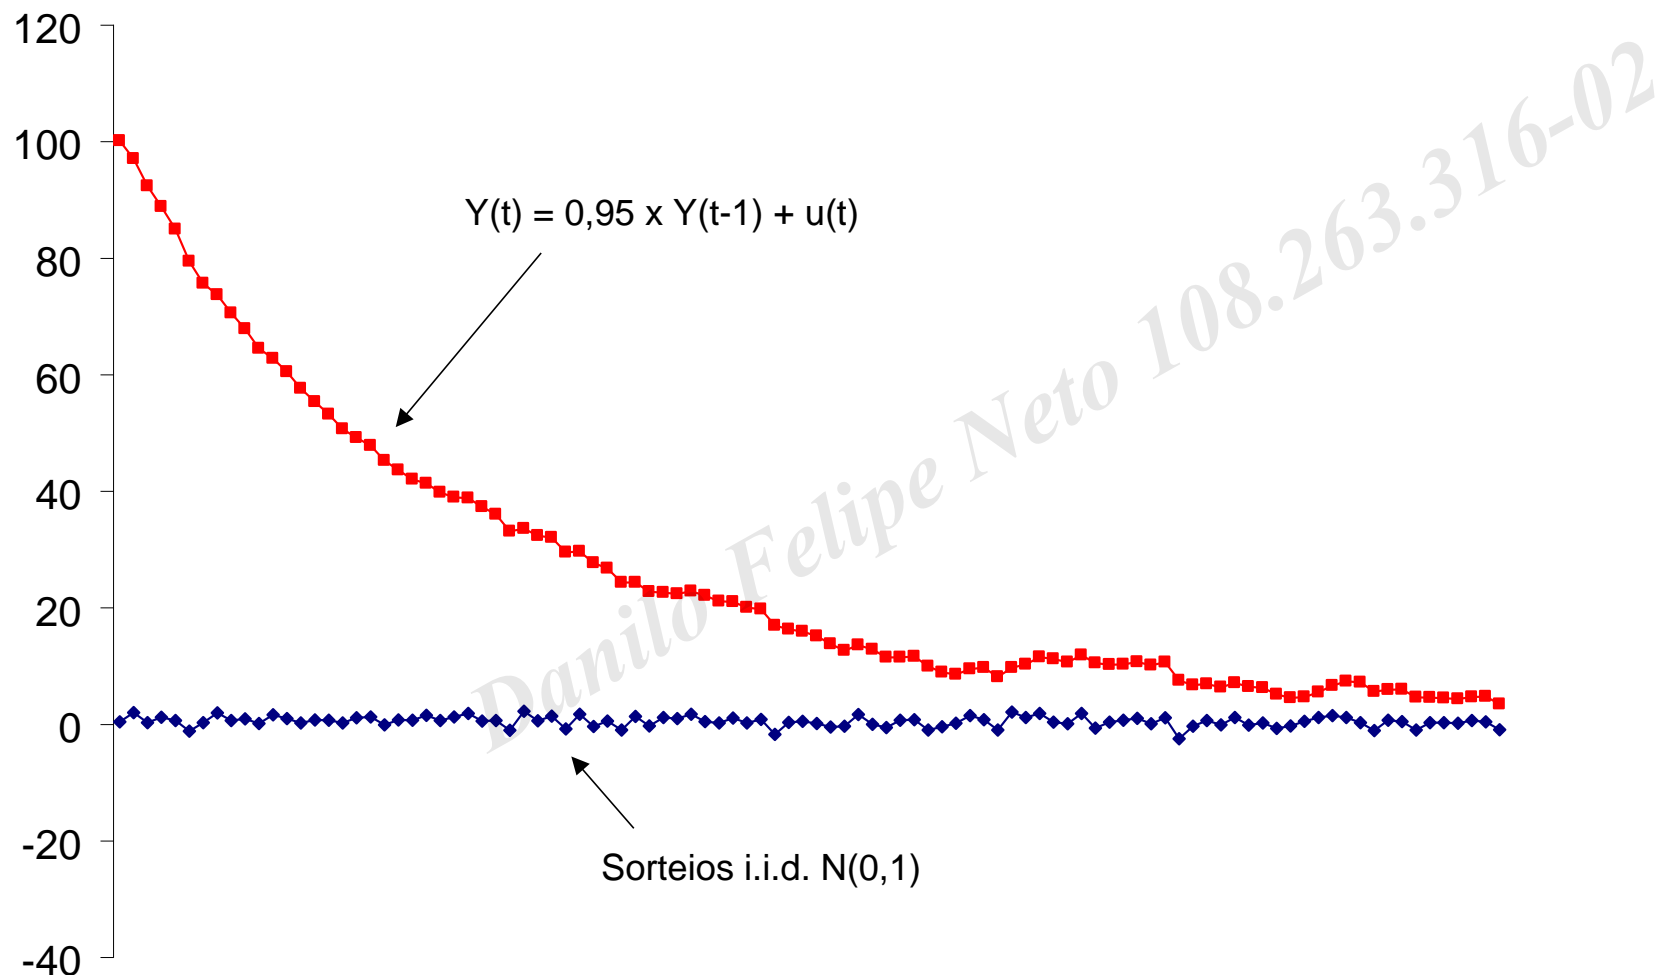
$ARMA(1,1)$

$$X_t = -0,8X_{t-1} - 0,3\varepsilon_{t-1} + \varepsilon_t$$




Exemplo: Processo AR(1) de baixa frequência

$$Y_t = 0,95 \times Y_{t-1} + u_t, \quad Y_0 = 100, \quad u_t \sim N(0,1)$$



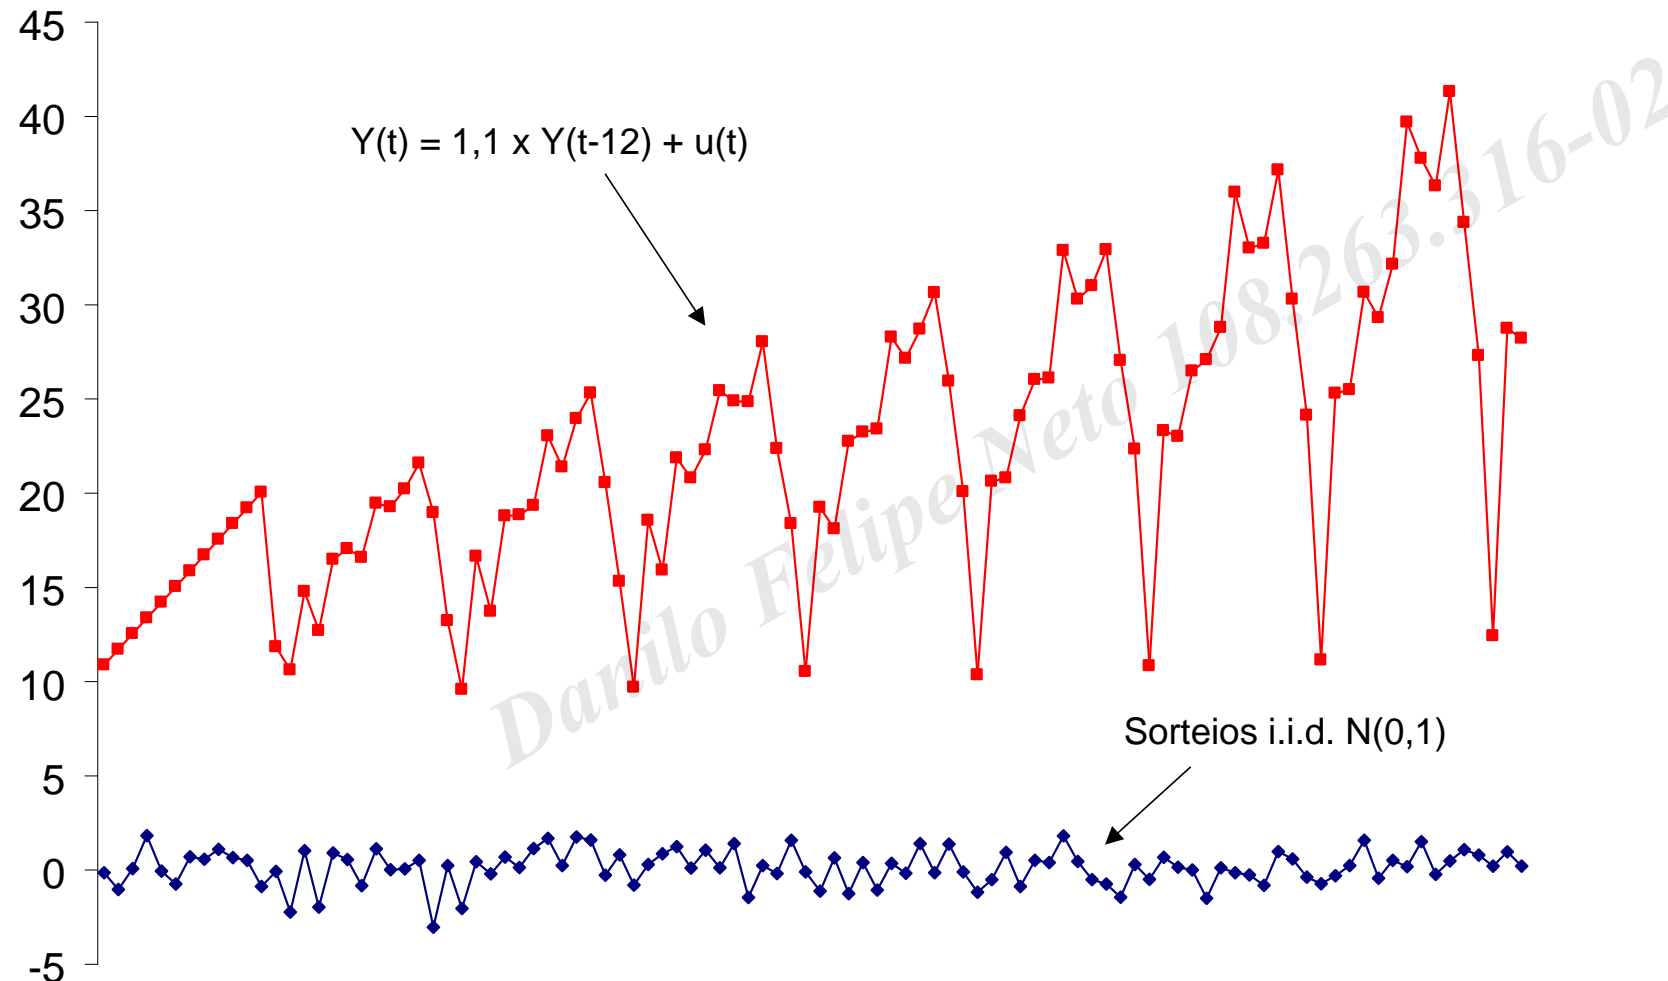
Exemplo: Processo AR(1) de baixa frequência

$$Y_t = -0,95 \times Y_{t-1} + u_t, \quad Y_0 = 100, \quad u_t \sim N(0,1)$$



Exemplo: Processo AR(12):

$$Y_t = 1,1 \times Y_{t-12} + u_t, \quad Y_0 = 10, \quad u_t \sim N(0,1)$$



Modelos Auto-regressivos (AR)

- Os valores correntes de uma série Y_t dependem apenas de seus valores passados e dos erros aleatórios.
- Exemplo AR(p): p é o número de defasagens

Modelo AR(1)

$$Y_t = \phi_1 Y_{t-1} + \varepsilon_t$$

Teste de Estacionariedade

[...] um processo estocástico é estacionário se suas média e variância forem constantes ao longo do tempo e o valor da covariância entre dois períodos de tempo depender apenas da distância ou defasagem entre os dois períodos, e não do período de tempo efetivo em que a covariância é calculada (ENDERS, 2003).

Teste KPSS – Kwiatkowski-Phillips-Schmidt - Shin

H_0 : a série é estacionária (Não apresenta raiz unitária)

H_1 : a série Não é estacionária (Possui raiz unitária)

Teste de Estacionariedade

Teste de Dickey-Fuller

Teste feito porque não se sabe se a série temporal possui mais de uma raiz unitária, pois o número de termos de diferenças defasadas é, muitas vezes, determinado empiricamente.

H_0 : a série não é estacionária (apresenta raiz unitária)

H_1 : a série é estacionária (sem raiz unitária)

Teste PP – Phillips-Perron

H_0 : a série não é estacionária (apresenta raiz unitária)

H_1 : a série é estacionária (sem raiz unitária)

Autocorrelação

- Coeficiente de Correlação de Perason (r)
- Coeficiente de Determinação (R^2)
- Autocorrelação
 - Mede se existe uma relação matemática entre os intervalos da série temporal
 - Também deve estar entre -1 e $+1$, sendo zero a ausência de autocorrelação.
 - Medida em intervalos (*lags*)
 - 1 intervalo: mede como os valores de 1 período (vizinhos) distante estão relacionados
 - 2 intervalos: mede com os valores de 2 períodos distantes estão relacionados

Autocorrelação

É o coeficiente de correlação entre observações defasadas no tempo:

$$r_1 = \frac{\sum_{t=1}^{n-1} (x_t - \bar{x}_1)(x_{t+1} - \bar{x}_2)}{\sqrt{\sum_{t=1}^{n-1} (x_t - \bar{x}_1)^2 (x_{t+1} - \bar{x}_2)^2}}$$

onde as médias amostrais são:

$$\bar{x}_1 = \sum_{i=1}^{n-1} x_t / (n-1) \quad \text{e} \quad \bar{x}_2 = \sum_{i=2}^n x_t / (n-1)$$

Função de Autocorrelação $FAC(k)$

A expressão anterior pode ser generalizada para k períodos de tempo (defasagem):

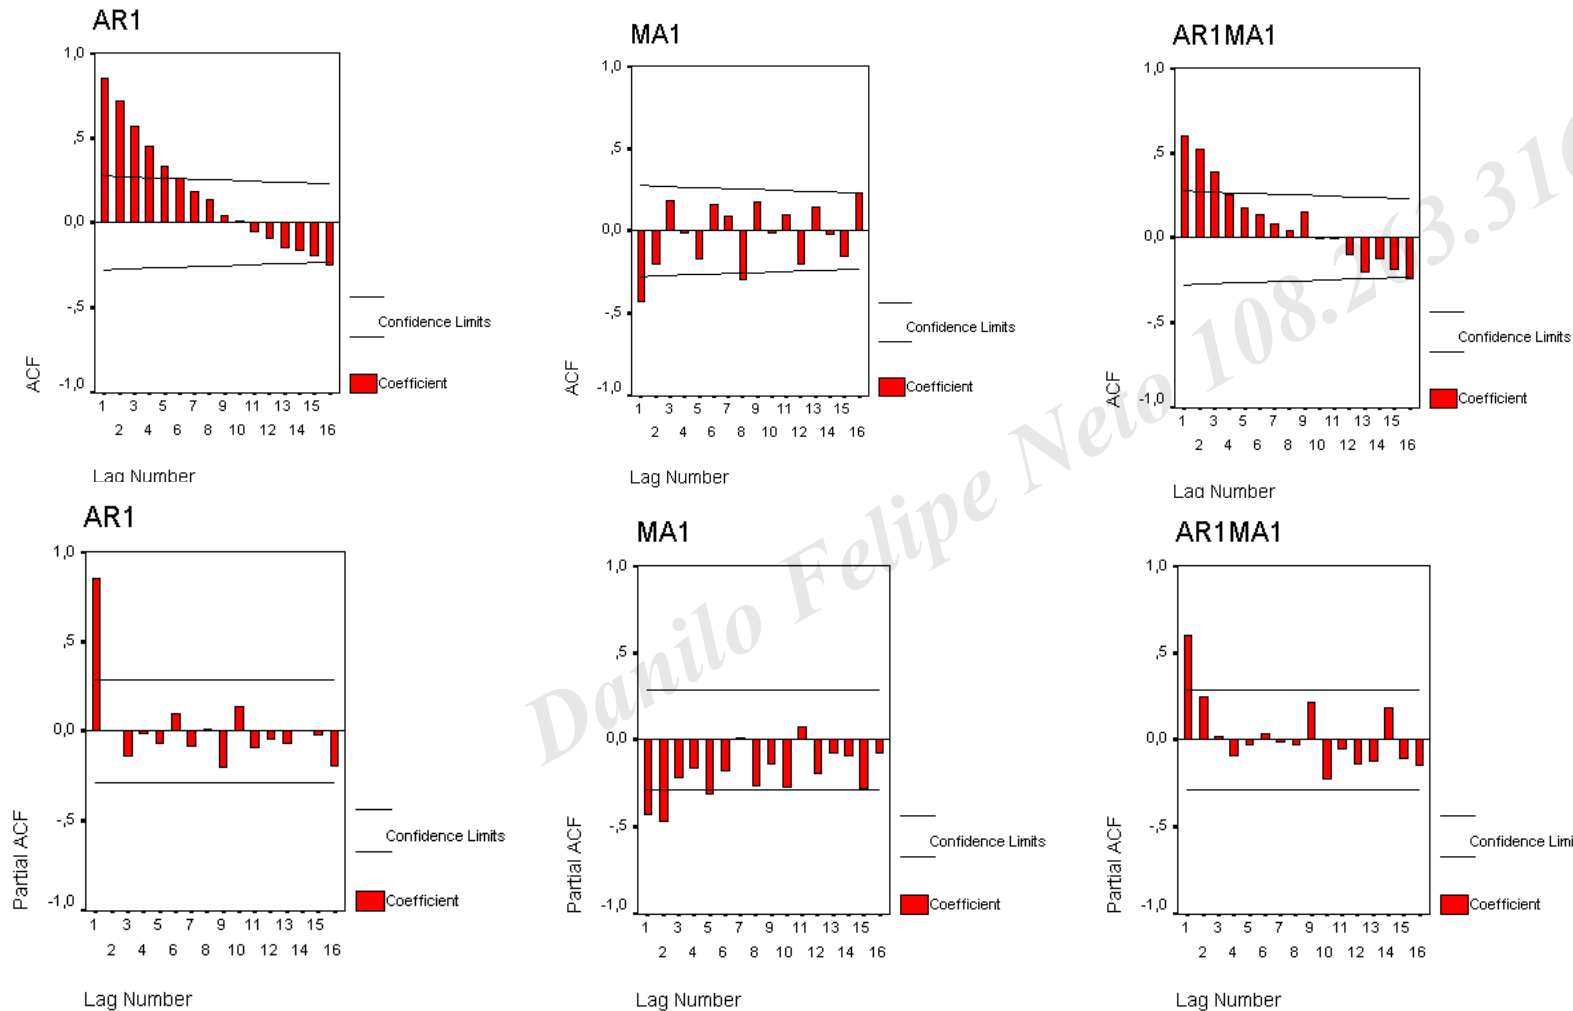
$$r_k = FAC(k) = \frac{\sum_{t=1}^{n-k} (x_t - \bar{x})(x_{t+k} - \bar{x})}{\sum_{t=1}^{n-1} (x_t - \bar{x})^2}$$

Como, tanto a covariância como a variância apresentam as mesmas unidades, não tem unidade. Oscila entre -1 e 1 e o gráfico feito colocando contra k é chamado de **correlograma amostral** da FAC.

Correlogramas

- **FAC (ACF)** – Função de Autocorrelação
 - Mostra as autocorrelações em uma série temporal
 - Linhas mostram significância (intervalo de confiança)
 - A 1ª autocorrelação é igual a 1. Cada traço do gráfico mostra uma defasagem e uma correlação (autocorrelação).
- **FACP (PACF)** – Função de Autocorrelação Parcial
 - Mede a autocorrelação não entre *lags* mas entre diferentes intervalos.

FAC dos Modelos Simulados



Características da FAC

| | Padrão típico da FAC | Padrão típico da FACP |
|-----------|---|---|
| AR(p) | Decai exponencialmente para zero ou com padrão de onda senoidal amortecida, ou ambos. | Valores significativos, ou seja, não nulos, até a defasagem p |
| MA(q) | Valores significativos, ou seja, não nulos, até a defasagem q | Decai exponencialmente para zero. |
| ARMA(p,q) | Decai exponencialmente para zero. | Decai exponencialmente para zero. |

Metodologia de Box-Jenkins

| Etapas | Processo |
|---------------|---|
| Identificação | descobrir os valores apropriados de p e q . Para isso usamos o correlograma e o correlograma parcial para perceber em que períodos de defasagem existe mais correlação com a variável dependente ou de correlação entre as observações com k períodos de defasagem. |
| Estimação | estimar os parâmetros dos termos auto-regressivo e de média móvel incluídos no modelo |
| Checagem | Um teste simples do modelo escolhido é ver se os resíduos estimados desse modelo são ruídos brancos; se são, podemos aceitar o ajuste específico; se não são, devemos começar tudo de novo. |

Modelo ARIMA(p,d,q)

Pode-se pensar num modelo ARIMA como uma função de regressão populacional para Y_t em que há apenas 2 tipos de “variáveis explicativas”:

- (1) Valores passados de $Y_t \rightarrow$ A parte “autorregressiva”.
- (2) Valores presente e passados do distúrbio normal u_t (ou “inovação”) \rightarrow A parte de “médias móveis”.

$$Y_t = \phi_1 Y_{t-1} + \dots + \phi_p Y_{t-p} + u_t - \theta_1 u_{t-1} - \dots - \theta_q u_{t-q}$$

- Hiperparâmetro p : a defasagem máxima de Y_t presente na equação.
- Hiperparâmetro q : a defasagem máxima de u_t presente na equação.
- Hiperparâmetro d : ordem de integração, se o processo for não-estacionário

Modelo AR(p) - Fundamentos

- Um processo linear **estacionário** auto-regressivo de ordem p, ou simplesmente AR(p), é definido como:

$$Y_t = \rho Y_{t-1} + \rho Y_{t-2} + \dots + \rho Y_{t-p} + \varepsilon_t$$

Ruído Branco

Uma sequência ε_t é um processo ruído branco se, para qualquer t:

- 1) $E(\varepsilon_t) = 0 \rightarrow$ **média constante e nula**
- 2) $\text{Var}(\varepsilon_t) = E(\varepsilon_t^2) \rightarrow$ **variância constante**
- 3) $\text{Cov}(\varepsilon_t, \varepsilon_{t-1}) = E(\varepsilon_t \varepsilon_{t-1}) = 0 \rightarrow$ **ausência de autocorrelação**

Se $\varepsilon_t \sim N$, então será Ruído Branco Gaussiano

Classes de modelos

Exemplos de modelos da classe ARIMA:

- **Modelo AR(1):** $Y_t = \phi_1 Y_{t-1} + u_t$
- **Modelo AR(2):** $Y_t = \phi_1 Y_{t-1} + \phi_2 Y_{t-2} + u_t$
- **Modelo MA(1):** $Y_t = u_t - \theta_1 u_{t-1}$
- **Modelo ARMA(1,1):** $Y_t = \phi_1 Y_{t-1} + u_t - \theta_1 u_{t-1}$

Modelo ARIMA SAZONAL

Modelo SARIMA(p,d,q)(P,D,Q)

- Notação: SARIMA (0,0,0) (1,0,0)₁₂

$$Y_t = \alpha + \phi Y_{t-1} + \epsilon_t$$

- Notação: SARIMA (0,0,0) (0,0,1)₁₂

$$Y_t = \alpha + \theta \epsilon_{t-12} + \epsilon_t$$

- Generalizando: SARIMA(p,d,q)(P,D,Q)_s
- P - número de termos auto regressivos sazonais (defasagens no lado direito da equação)
- d – número de diferenças sazonais
- q – número de médias móveis sazonais (erros defasados no lado direito da equação)
- s – ciclo sazonal

Teste de Normalidade

Assimetria $A(X) = E\left[\frac{(X - \mu)^3}{\sigma^3}\right]$

Curtose $K(X) = E\left[\frac{(X - \mu)^4}{\sigma^4}\right]$

Normal: $A = 0$ e $K = 3$

Teste de Jarque Bera (1981) $JB = \left(\frac{n}{6}\right)A^2 + \left(\frac{n}{24}\right)(K - 3)^2$

H_0 : série é normal

$$JB \sim \chi^2(2)$$

OBRIGADO!

[linkedin.com/in/fabiano-guasti-lima-b9830282](https://www.linkedin.com/in/fabiano-guasti-lima-b9830282)